

PREDICCIÓN MUSICAL

Guía Completa del Proyecto TFM

Predictor de demanda de conciertos en Granada

Fase 1: Recolección de Datos

Versión 1.0 - Marzo 2026

ÍNDICE DEL DOCUMENTO

1. VISIÓN GENERAL DEL PROYECTO
2. ROADMAP TEMPORAL (Marzo - Junio 2026)
3. FASE 1: RECOLECCIÓN DE DATOS (DETALLADO)
 - 3.1. Fuentes de Datos Identificadas
 - 3.2. Configuración de Spotify API
 - 3.3. Web Scraping de Conciertos en Granada
 - 3.4. Creación de Variable Proxy para Ocupación
 - 3.5. Estructura de la Base de Datos
4. ARQUITECTURA TÉCNICA
5. CÓDIGO BASE PARA EMPEZAR
6. PRÓXIMOS PASOS Y ENTREGABLES
7. RECURSOS Y ANEXOS

1. VISIÓN GENERAL DEL PROYECTO

Objetivo del TFM

Desarrollar un sistema de predicción de demanda para conciertos de artistas urbanos emergentes (10K-500K oyentes mensuales en Spotify) en salas de Granada, utilizando machine learning y datos de múltiples fuentes.

Problema a Resolver

Los artistas emergentes y las salas de conciertos no tienen herramientas para estimar la demanda real de un evento, lo que resulta en:

- Pérdidas económicas por salas demasiado grandes o pequeñas
- Eventos cancelados por falta de ventas anticipadas
- Oportunidades perdidas de maximizar ingresos

Solución Propuesta

Un modelo predictivo que clasifica la demanda en tres categorías (Alta/Media/Baja) y recomienda el tamaño de sala óptimo, basándose en:

- Métricas de Spotify del artista
- Histórico de conciertos en Granada
- Señales indirectas de demanda (redes sociales, sold outs)
- Temporalidad y características del evento

Alcance del MVP

DIMENSIÓN	ALCANCE MVP
Artistas	Género urbano español (10K-500K oyentes) Ejemplos: Tarchi, Guxo, Bon Calso, C Marí
Salas	5-6 salas en Granada: • Sala Víbora • Industrial Copera • Sala Aliatar • Planta Baja • Sala El Tren
Período datos	2023-2025 (3 años históricos)
Variable objetivo	Demanda: Baja / Media / Alta + Probabilidad de sold out
Usuarios objetivo	Promotores, managers, salas de conciertos

2. ROADMAP TEMPORAL (Marzo - Junio 2026)

El proyecto se divide en 4 fases principales con hitos claros:

FASE	PERÍODO	ENTREGABLES CLAVE
FASE 1 Recolección de Datos	Marzo - Abril (6 semanas)	✓ Dataset de artistas (100-150 artistas) ✓ Dataset de conciertos Granada (200+ eventos) ✓ Dataset de salas (5-6 salas) ✓ Variable proxy de ocupación ✓ Base de datos estructurada
FASE 2 Ingeniería de Features	Abril - Mayo (3 semanas)	✓ Features de artista normalizadas ✓ Features temporales ✓ Features de sala ✓ Análisis exploratorio (EDA) ✓ Dataset limpio y listo para ML
FASE 3 Modelo de ML	Mayo (3 semanas)	✓ Modelo entrenado y validado ✓ Métricas de rendimiento ✓ Explicabilidad del modelo ✓ Notebook de experimentación
FASE 4 Despliegue MVP	Mayo - Junio (2 semanas)	✓ Dashboard Streamlit funcional ✓ API de predicción ✓ Documentación ✓ Memoria del TFM

 **ESTÁS AQUÍ: Inicio de la Fase 1 - Recolección de Datos**

3. FASE 1: RECOLECCIÓN DE DATOS (DETALLADO)

3.1. Fuentes de Datos Identificadas

FUENTE	DATOS A EXTRAER	MÉTODO	DIFICULTAD
Spotify API	• Oyentes mensuales • Seguidores • Popularidad (0-100) • Géneros • Top tracks	API oficial	☆ Fácil
conciertosengranada.es	• Histórico de conciertos • Fechas • Salas • Artistas	Web scraping	☆☆ Media
Instagram/Twitter	• Posts con #SOLDOUT • Engagement del evento • Menciones del artista	APIs sociales / Scraping	☆☆☆ Alta
Validación Manual	• 30-50 conciertos conocidos • Nivel de ocupación real	Memoria personal Preguntas en redes	☆☆ Media
Google Trends	• Tendencia del artista • Búsquedas relacionadas	API de Trends	☆ Fácil

3.2. Configuración de Spotify API

Paso 1: Crear cuenta de desarrollador

1. Ve a <https://developer.spotify.com/dashboard>
2. Inicia sesión con tu cuenta de Spotify
3. Crea una nueva aplicación (nombre: 'Predicción Musical TFM')
4. Copia tu CLIENT_ID y CLIENT_SECRET

Paso 2: Instalación de librerías Python

```
pip install spotipy python-dotenv pandas requests beautifulsoup4
```

Paso 3: Estructura de archivos

```
prediccion_musical/ ├── .env (credenciales) ├── scripts/ | | ├── spotify_collector.py | | ├── web_scraper.py | | ├── data_merger.py | | ├── data/ | | ├── raw/ | | ├── processed/ | | ├── final/ | | ├── notebooks/ | | └── exploratory_analysis.ipynb
```

Paso 4: Ejemplo de código para obtener datos de artista

Ver sección 5 (Código Base) para el script completo de Spotify.

3.3. Web Scraping de Conciertos en Granada

IMPORTANTE: Antes de hacer scraping, debes verificar que el sitio web lo permite. Revisa el archivo robots.txt y los términos de servicio.

Estrategia de scraping

- Identificar URLs de búsqueda por año/género
- Extraer: artista, fecha, sala, hora
- Buscar menciones de 'sold out', 'agotado', 'completo'
- Guardar HTMLs localmente para re-procesamiento

Pasos detallados

5. Analizar estructura HTML de conciertosengranada.es
6. Identificar selectores CSS para cada campo
7. Implementar rate limiting (1-2 segundos entre requests)
8. Validar datos extraídos manualmente (sample de 20 eventos)
9. Iterar sobre años 2023, 2024, 2025

 [Ver sección 5 para el código completo del web scraper.](#)

3.4. Creación de Variable Proxy para Ocupación

Este es el componente más innovador del proyecto. Al no tener datos exactos de ocupación, crearemos una variable proxy combinando múltiples señales.

Sistema de Puntuación Proxy

SEÑAL	FUENTE	PUNTOS	CÓMO DETECTAR
Sold Out confirmado	Web evento / RRSS	+3	Palabras: 'sold out', 'agotadas', 'completo'
Alta actividad RRSS	Instagram/Twitter	+2	>50 posts con hashtag del evento
Segunda fecha	Web conciertos	+2	Artista repite en <30 días
Menciones 'no conseguí'	Twitter/Instagram	+1	Búsqueda de frases clave
Fotos/videos lleno	Instagram	+2	Análisis manual de publicaciones
Precio premium	Web entradas	+1	Precio >30€ para sala pequeña

Clasificación final:

- Alta demanda: ≥ 6 puntos
- Media demanda: 3-5 puntos
- Baja demanda: 0-2 puntos

Validación con casos conocidos

Para validar este sistema, crearás un dataset manual de 30-50 conciertos que TÚ recuerdes o puedas verificar:

- Pregunta en grupos de Facebook/Instagram de Granada
- Busca fotos en redes sociales del público
- Consulta con amigos que asistieron

3.5. Estructura de la Base de Datos

Diseñaremos 3 tablas principales que se relacionarán entre sí:

Tabla 1: artistas.csv

CAMPO	TIPO	DESCRIPCIÓN	FUENTE
artist_id	string	ID único del artista	Spotify URI
nombre	string	Nombre del artista	Spotify
oyentes_mensuales	int	Oyentes mensuales actuales	Spotify
seguidores	int	Seguidores totales	Spotify
popularidad	int	Métrica 0-100	Spotify
generos	string	Lista de géneros	Spotify
total_conciertos	int	Conciertos realizados	Calculado
ya_toco_granada	boolean	Si tocó en Granada antes	Calculado

Tabla 2: salas.csv

CAMPO	TIPO	DESCRIPCIÓN	EJEMPLO
sala_id	string	ID único	sala_vibora
nombre	string	Nombre de la sala	Sala Víbora
aforo_max	int	Capacidad máxima	500
tipo	string	club/concierto/festival	club
ubicacion	string	Zona de Granada	Centro

Tabla 3: conciertos.csv

CAMPO	TIPO	DESCRIPCIÓN
concierto_id	string	ID único del evento
artist_id	string	FK a artistas
sala_id	string	FK a salas
fecha	date	YYYY-MM-DD
mes	int	1-12
dia_semana	string	Lunes-Domingo
temporada	string	alta/media/baja
proxy_demanda	int	Puntuación 0-10

clase_demanda	string	baja/media/alta
oyentes_en_fecha	int	Oyentes del artista en esa fecha

4. ARQUITECTURA TÉCNICA

Stack tecnológico recomendado para el proyecto:

COMPONENTE	TECNOLOGÍA	JUSTIFICACIÓN
Lenguaje principal	Python 3.10+	Ecosistema ML más maduro
APIs	spotipy, requests	Acceso a Spotify y scraping
Base de datos	SQLite / Snowflake	SQLite para desarrollo, Snowflake para producción
ML Framework	scikit-learn	Perfecto para modelos clásicos
Análisis	pandas, numpy	Manipulación de datos
Visualización	matplotlib, seaborn	EDA y gráficos
Dashboard	Streamlit	Rápido de desarrollar, intuitivo
Versionado	Git + GitHub	Control de versiones
Entorno	conda / venv	Gestión de dependencias

Flujo de Datos

1. EXTRACCIÓN → APIs (Spotify) + Web Scraping (conciertos) 2. TRANSFORMACIÓN → Limpieza, normalización, feature engineering 3. CARGA → Base de datos (SQLite/Snowflake) 4. MODELADO → Entrenamiento con scikit-learn 5. DESPLIEGUE → Streamlit dashboard + API Flask

5. CÓDIGO BASE PARA EMPEZAR

A continuación encontrarás código listo para usar. Copia estos scripts y adáptalos a tus necesidades.

5.1. Archivo .env (Credenciales)

```
SPOTIFY_CLIENT_ID=tu_client_id_aqui  
SPOTIFY_CLIENT_SECRET=tu_client_secret_aqui
```

5.2. spotify_collector.py

Ver código completo en los archivos adjuntos # Este script recopila datos de artistas desde Spotify # Uso: python scripts/spotify_collector.py

5.3. web_scraper.py

Ver código completo en los archivos adjuntos # Script para extraer conciertos de conciertosengranada.es # Uso: python scripts/web_scraper.py

6. PRÓXIMOS PASOS Y ENTREGABLES

Checklist Fase 1 (Próximas 6 semanas)

Semana 1-2: Configuración y extracción inicial

- ☐ Configurar cuenta Spotify Developer
- ☐ Instalar dependencias Python
- ☐ Crear estructura de carpetas del proyecto
- ☐ Listar 100 artistas objetivo (10K-500K oyentes)
- ☐ Extraer datos de 20 artistas (prueba)

Semana 3-4: Web scraping y datos de salas

- ☐ Analizar estructura HTML de conciertosengranada.es
- ☐ Implementar scraper básico
- ☐ Extraer conciertos 2023-2025 (200+ eventos)
- ☐ Crear tabla de salas con aforos
- ☐ Validar datos extraídos (muestra de 30 eventos)

Semana 5-6: Variable proxy y consolidación

- ☐ Buscar señales de sold out en redes sociales
- ☐ Calcular puntuación proxy para cada concierto
- ☐ Crear dataset de validación manual (30-50 casos)
- ☐ Unir todas las tablas en base de datos
- ☐ Documentar proceso de recolección

7. RECURSOS Y ANEXOS

Documentación oficial

- Spotify Web API: <https://developer.spotify.com/documentation/web-api>
- spotipy (Python wrapper): <https://spotipy.readthedocs.io/>
- BeautifulSoup4: <https://beautiful-soup-4.readthedocs.io/>
- pandas: <https://pandas.pydata.org/docs/>
- scikit-learn: <https://scikit-learn.org/stable/>
- Streamlit: <https://docs.streamlit.io/>

Artistas de ejemplo (género urbano español)

Esta lista te servirá como punto de partida para extraer datos:

- Tarchi
- Guxo
- Bon Calso
- C Marí
- AmoryOdio
- ladiferencia2006
- (Ampliar hasta 100-150 artistas similares)

Salas de Granada identificadas

SALA	AFORO APROX.	TIPO
Sala Víbora	300-400	Club
Industrial Copera	800-1000	Polivalente
Sala Aliatar	200-300	Sala pequeña
Planta Baja	400-500	Club/Concierto
Sala El Tren	600-800	Sala mediana

Sugerencias de mejora para futuras versiones

- Expandir a más ciudades (Málaga, Sevilla, Madrid)
- Incluir análisis de sentimiento de comentarios en redes
- Integrar precios de entradas como feature
- Añadir competencia (otros eventos el mismo día)
- Automatizar actualización de datos cada semana
- Crear API REST para integración con plataformas de venta

NOTAS FINALES

Recuerda:

- Este documento es tu guía de referencia, pero adapta todo a tus necesidades específicas.
- Documenta cada paso que des: será valioso para la memoria del TFM.
- No te obsesiones con la perfección en la Fase 1: el objetivo es tener datos suficientes y razonablemente limpios.
- La variable proxy es una solución creativa a un problema real: documéntala bien como contribución metodológica.
- Mantén contacto con tu tutor y comparte avances semanales.

Objetivo inmediato:

En las próximas 2 semanas, tu meta es conseguir: ✓ Credenciales de Spotify configuradas ✓ Lista de 100 artistas objetivo ✓ Datos de 50 artistas extraídos de Spotify ✓ Estructura de carpetas del proyecto creada ✓ Primer prototipo del web scraper funcionando ¡Mucha suerte con tu TFM! 